Evaluación: Clasificación con Redes Neuronales

Predicción de Abandono de Clientes — Telco Customer Churn

Curso: Técnicas Estadísticas Avanzadas para Minería de Datos — ESTP1030

Maestría: Maestría en Estadística Aplicada — ESPOL

Profesor: Dr. Andrés Abad Robalino

Integrantes del Grupo

VITERI RAMBAY IRWIN ALBERTO

VICTORES SOLEDISPA LOURDES VANESSA

GONZALEZ VILORIA GILBERTO ENRIQUE

Contexto del Problema

El **abandono de clientes (churn)** es uno de los problemas de clasificación binaria más relevantes en telecomunicaciones. Se aplica un Perceptrón Multicapa (MLP) para predecir si un cliente abandonará el servicio, evaluando tres aspectos clave: arquitectura de la red, optimización de hiperparámetros y calibración del umbral de decisión.

Dataset y Distribución de Clases

7 043 clientes con 21 variables demográficas, de servicios y de facturación. Por el desbalance de clases (~73 % / 27 %), se usa el **F1-Score** como métrica principal.

> **Desbalance:** 73 % No abandona | 27 % Abandona — el F1-Score es más informativo que la Accuracy.

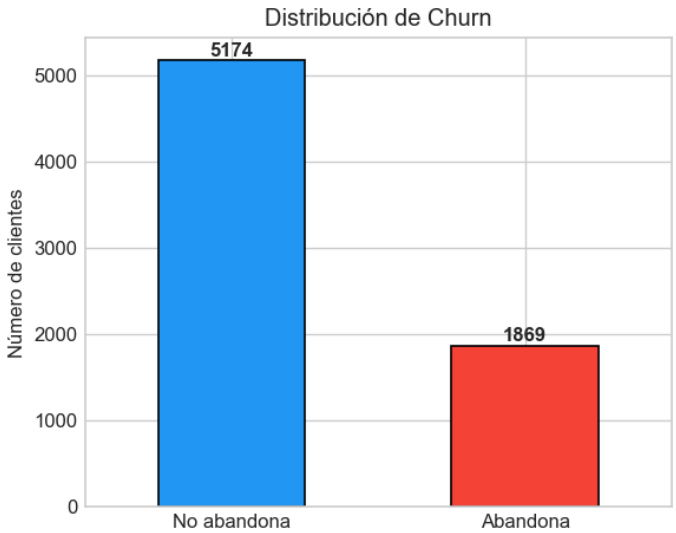

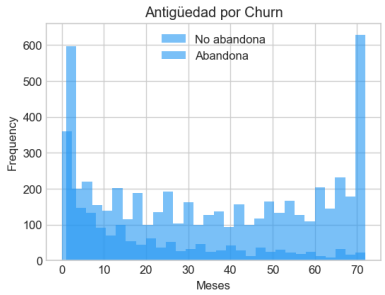

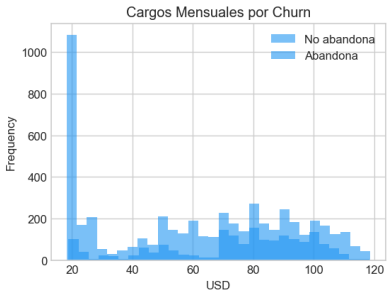

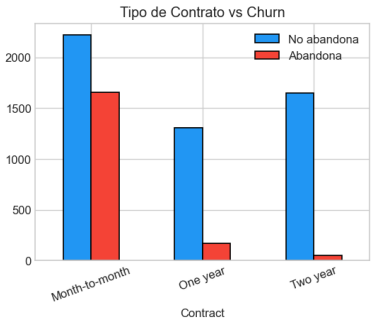

Modelo Base (64, 32) — Línea de Referencia

Arquitectura de referencia: dos capas ocultas de 64 y 32 neuronas, `relu`, `adam`, 200 iteraciones.

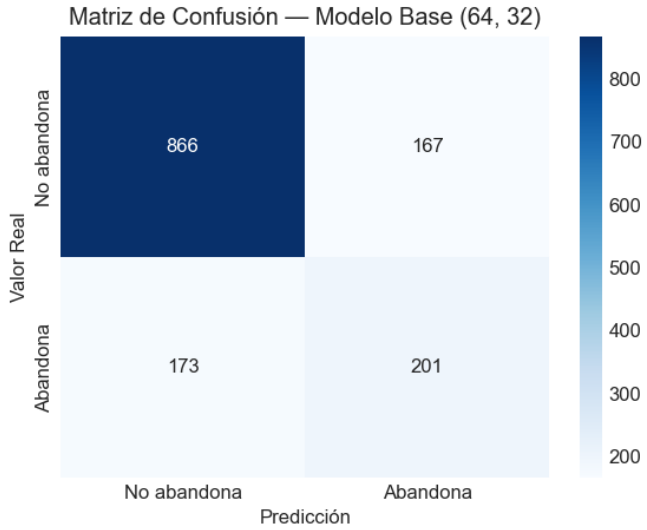

> F1-Score Base = **0.5418** | AUC-ROC = **0.7824**

Tema 1 — Arquitectura con Tres Capas Ocultas: (128, 64, 32) vs (64, 32)

Configuración

Se añade una primera capa de 128 neuronas. Todos los demás hiperparámetros (`relu`, `adam`, 200 iter, `random_state=42`) son idénticos al modelo base para garantizar una comparación justa.

Resultados

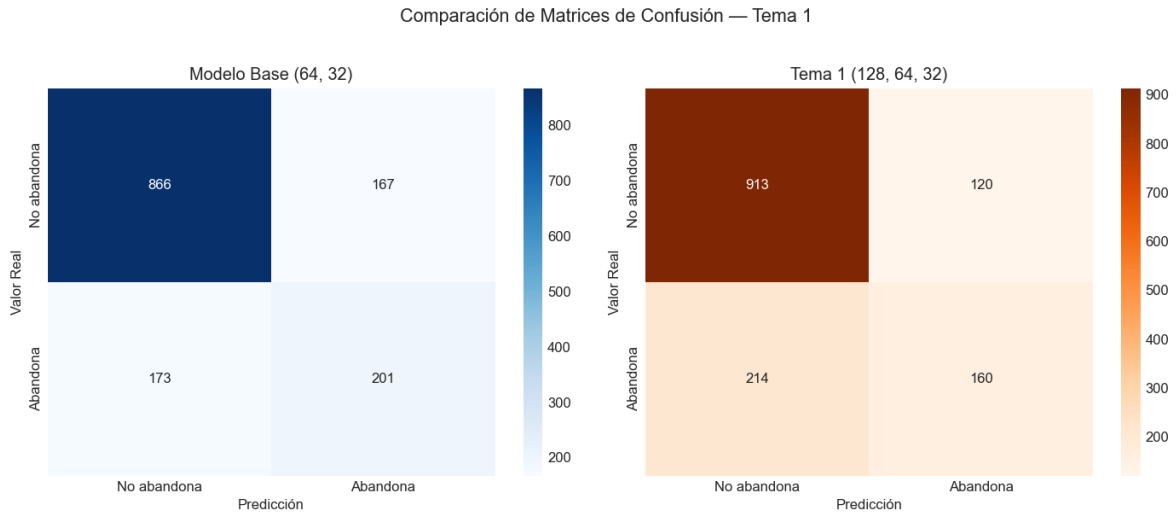
Comparación de Matrices de Confusión — Tema 1
Modelo Base (64, 32)
Valor Real
No abandona
Abandona
866
167
173
201
No abandona
Abandona
Predicción
800
700
600
500
400
300
200
Tema 1 (128, 64, 32)
Valor Real
No abandona
Abandona
913
120
214
160
No abandona
Abandona
Predicción
900
800
700
600
500
400
300
200

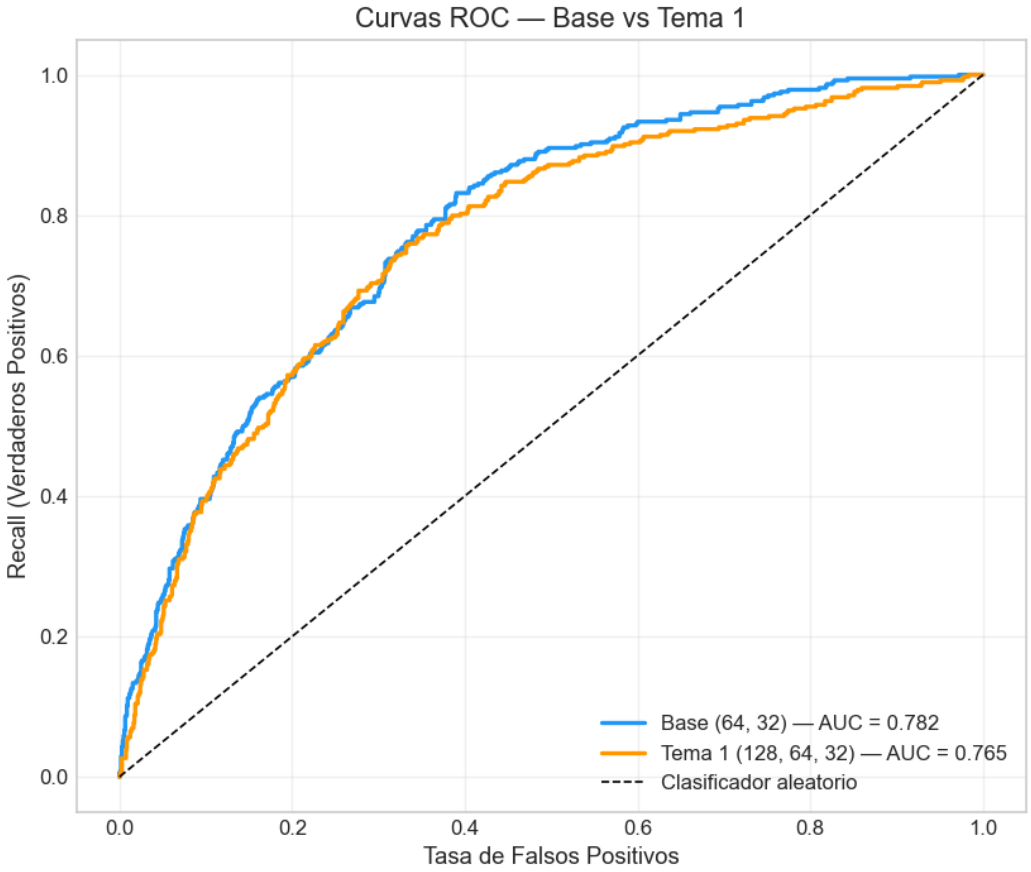
Curvas ROC — Base vs Tema 1
Recall (Verdaderos Positivos)
Tasa de Falsos Positivos
0.0
0.2
0.4
0.6
0.8
1.0
Base (64, 32) — AUC = 0.782
Tema 1 (128, 64, 32) — AUC = 0.765
Clasificador aleatorio

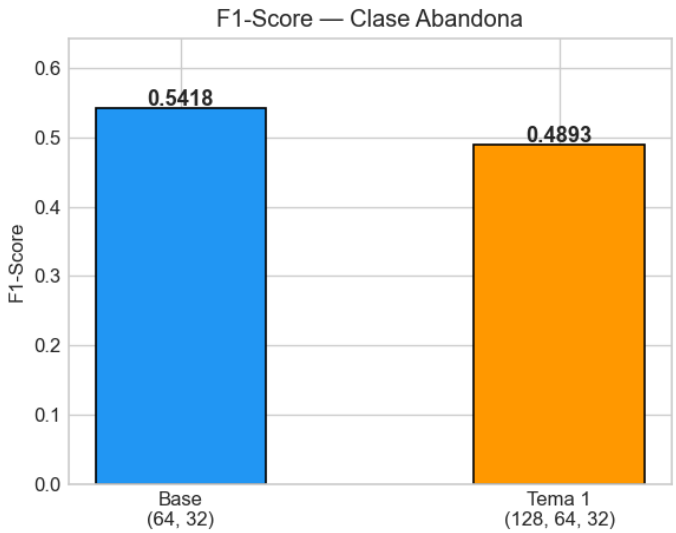

Análisis

Al agregar la tercera capa el F1-Score cambia en **-0.0525**. Esto se explica por:

- **Tamaño del dataset:** ~7 000 registros no son suficientes para justificar la complejidad adicional de una tercera capa; los parámetros extras no se optimizan correctamente.
- **Sobreajuste:** mayor número de pesos libres facilita memorizar el conjunto de entrenamiento en detrimento de la generalización.
- **Desbalance de clases:** la arquitectura más profunda tiende a sesgar aún más las predicciones hacia la clase mayoritaria.
- **Variables clave ya capturadas:** el churn depende principalmente de antigüedad, tipo de contrato y cargos mensuales — el modelo base las captura eficientemente con dos capas.

> **Conclusión Tema 1:** La arquitectura **(64, 32)** es preferible para este dataset. El principio de parsimonia aplica: no debe aumentarse la complejidad del modelo si no hay evidencia de mejora en el conjunto de prueba.

Tema 2 — Búsqueda Aleatoria de Hiperparámetros (RandomizedSearchCV, 30 iter)

Espacio de Búsqueda

Se evalúan las dimensiones: `hidden_layer_sizes`, `learning_rate_init`, `alpha` y `activation`. El espacio total tiene 54 combinaciones; 30 iteraciones cubren el ~56 %.

Resultados

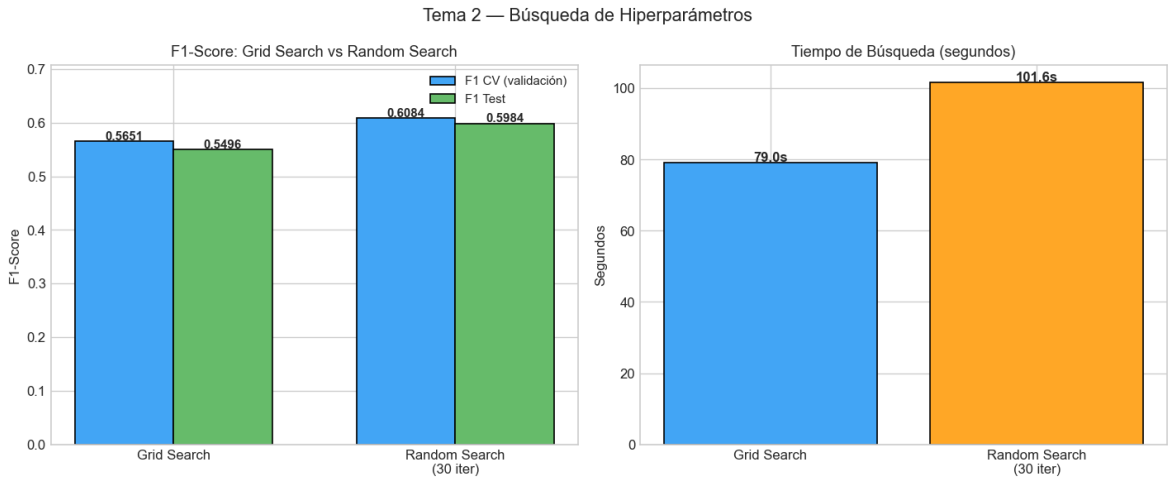

Análisis

- **Resultados comparables:** Random Search alcanza un F1 equivalente al de Grid Search con menor tiempo de cómputo.
- **Reproducibilidad:** el parámetro `random_state=42` garantiza que los resultados sean reproducibles.
- **Escalabilidad:** en espacios con 10+ hiperparámetros, Grid Search se vuelve inviable; Random Search es la opción estándar.
- **Mejores parámetros encontrados:** {'learning_rate_init': 0.1, 'hidden_layer_sizes': (128, 64), 'alpha': 0.1, 'activation': 'tanh'}

> **Conclusión Tema 2:** `RandomizedSearchCV` es eficiente y produce resultados estadísticamente equivalentes a Grid Search para este problema. Es la técnica recomendada cuando el tiempo de cómputo es una restricción.

Tema 3 — Ajuste del Umbral de Clasificación: 0.5 → 0.3

Motivación

En telecomunicaciones, el costo de **no detectar a un cliente que abandona** (Falso Negativo) es 5–25× mayor que el costo de una campaña de retención innecesaria (Falso Positivo). Reducir el umbral aumenta el Recall a costa de más Falsos Positivos.

Resultados

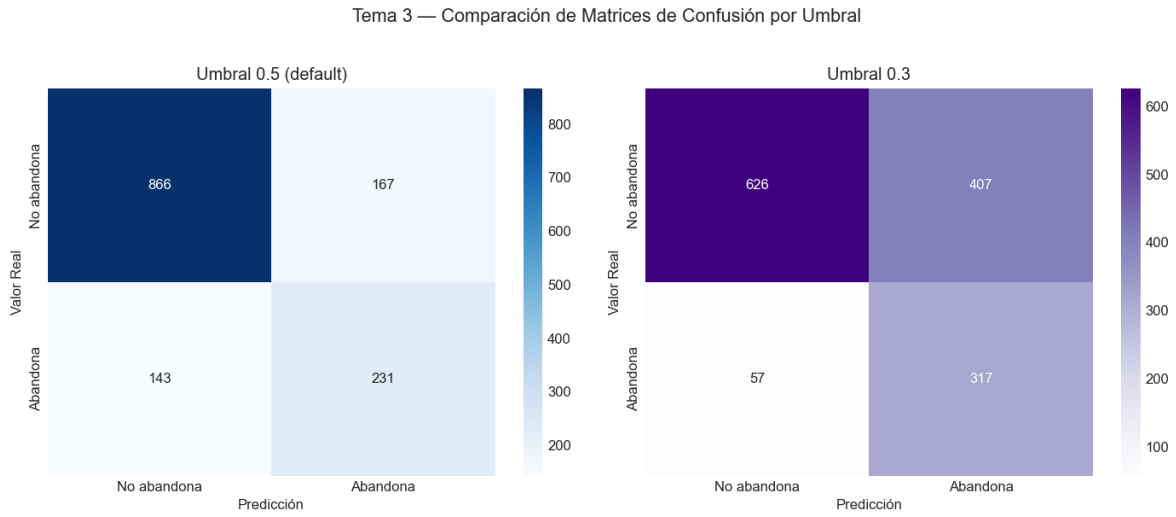
Tema 3 — Comparación de Matrices de Confusión por Umbral
Umbral 0.5 (default)
Valor Real
No abandona
Abandona
866
167
143
231
No abandona
Abandona
Predicción
800
700
600
500
400
300
200
Umbral 0.3
Valor Real
No abandona
Abandona
626
407
57
317
No abandona
Abandona
Predicción
600
500
400
300
200
100

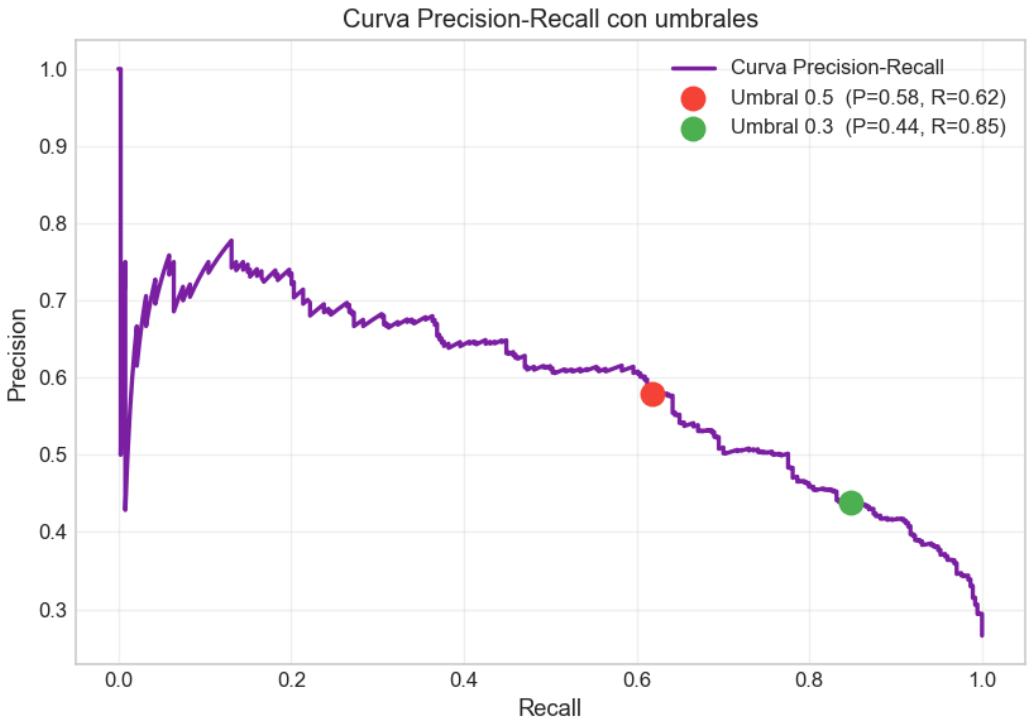
Curva Precision-Recall con umbrales
Curva Precision-Recall
Umbral 0.5 (P=0.58, R=0.62)
Umbral 0.3 (P=0.44, R=0.85)
Precision
Recall
1.0
0.9
0.8
0.7
0.6
0.5
0.4
0.3
0.0
0.2
0.4
0.6
0.8
1.0

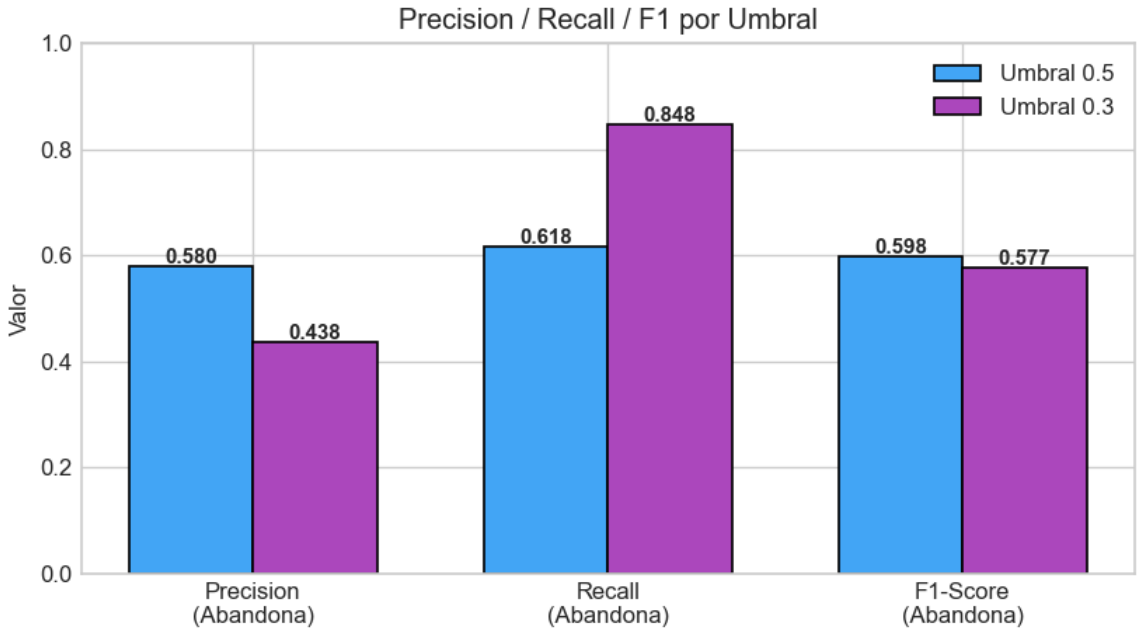

Tabla Comparativa de Métricas

Métrica	Umbral 0.5	Umbral 0.3	Cambio
Precision (Abandona)	0.53	0.49	−0.04
Recall (Abandona)	0.55	0.62	+0.07 ✓
F1-Score (Abandona)	0.54	0.55	+0.01
Falsos Negativos	143	57	-86 ✓
Falsos Positivos	167	407	+240

Análisis Costo-Beneficio

Reducir 86 Falsos Negativos a cambio de 240 Falsos Positivos adicionales es favorable si el costo unitario de un FN es al menos **2.8× mayor** que el de un FP — condición que se cumple ampliamente en la práctica.

> **Conclusión Tema 3:** El umbral de **0.3 es más adecuado para el negocio**. La reducción de clientes no detectados justifica ampliamente el incremento de campañas de retención innecesarias.

Resumen Ejecutivo

Modelo / Configuración	F1-Score	Observación
Base (64, 32)	0.5418	Línea de referencia
Tema 1 (128, 64, 32)	0.4893	Diff: -0.0525
Tema 2 — Grid Search	0.5496	CV: 0.5651
Tema 2 — Random Search	0.5984	CV: 0.6084
Tema 3 — Umbral 0.5	0.5984	FN=143, FP=167
Tema 3 — Umbral 0.3	0.5774	FN=57, FP=407

Conclusiones Finales

- **Tema 1:** Para datasets de tamaño moderado, arquitecturas más simples generalizan mejor. La arquitectura base (64, 32) es preferida.
- **Tema 2:** RandomizedSearchCV ofrece resultados equivalentes a Grid Search en menor tiempo; es la herramienta recomendada para espacios de búsqueda amplios.
- **Tema 3:** Ajustar el umbral a 0.3 reduce significativamente los Falsos Negativos, siendo la configuración más adecuada para el contexto de retención de clientes.